

**Pró-Reitoria Acadêmica
Curso de Ciências da Computação
INTELIGÊNCIA ARTIFICIAL**

**Explorando Toy Datasets do Scikit-Learn
Sistema de Previsão de Valor Imobiliário
Usando Random Forest e LINEAR Regression**

**Autor: Arthur Faria dos Santos
Guilherme Silva Tavares
Lara Dayrell Furbino
Lucas Francisco Custódio
Pedro Carneiro de Lima
Pedro Luís de Aquino**

Sumário

1. Introdução..... 3

2. Metodologia 3

3. Resultados..... 5

4. Discussão 6

5. Conclusão..... 7

6. Referências..... 8


1. Introdução

Este projeto desenvolveu uma solução de Machine Learning em Python para prever a variação dos valores imobiliários de Boston, servindo como uma ferramenta estratégica para corretores e compradores. A partir de uma base de dados robusta com 14 colunas, foi realizada uma rigorosa análise de qualidade (avaliando variância, valores nulos, mínimos e máximos), utilizando 13 dessas variáveis como recursos preditivos para estimar o valor final do imóvel (a meta). Os algoritmos Random Forest e Regressão Linear foram os modelos selecionados para o treinamento. Como impacto de negócio, a solução entrega uma precificação automatizada e precisa que reduz a margem de erro humana, otimiza a tomada de decisão e gerando insights valiosos para o mercado imobiliário.

2. Metodologia

O desenvolvimento do projeto seguiu um pipeline estruturado de ciência de dados, dividido nas seguintes etapas principais:

- **Análise Exploratória e Visualização:** Inicialmente, os dados do arquivo Boston Housing foram carregados utilizando a biblioteca Pandas. Foi realizada uma inspeção estatística descritiva para entender a distribuição das 14 colunas. Em seguida, com o auxílio das bibliotecas Matplotlib e Seaborn, foram geradas visualizações para analisar a distribuição da variável alvo (MEDV) e a dispersão de atributos altamente correlacionados, como o número de quartos (RM) e o status socioeconômico (LSTAT).





- CRIM: taxa de criminalidade per capita por cidade.
- ZN: proporção de terrenos residenciais zoneados para lotes com mais de 25.000 pés quadrados.
- INDUS: proporção de áreas destinadas a negócios não varejistas por cidade.
- CHAS: variável binária referente ao Rio Charles (= 1 se o setor censitário faz fronteira com o rio; 0 caso contrário).
- NOX: concentração de óxidos de nitrogênio (partes por 10 milhões).
- RM: número médio de cômodos por residência.
- AGE: proporção de unidades habitadas por proprietários construídas antes de 1940.
- DIS: distâncias ponderadas até cinco centros de emprego de Boston.
- RAD: índice de acessibilidade às rodovias radiais.
- TAX: taxa de imposto sobre propriedade por valor total, para cada US\$ 10.000.
- PTRATIO: razão aluno-professor por cidade.
- B: $1000(B-0,63)^2$, onde B é a proporção de pessoas negras na cidade.
- LSTAT: porcentagem da população de baixo status socioeconômico.
- MEDV: valor mediano das residências ocupadas por seus proprietários, em milhares de dólares (US\$ 1.000).
- Pré-processamento de Dados:
 - Seleção de Variáveis (Features): A variável alvo definida foi a MEDV. Avaliou-se o uso de todas as variáveis disponíveis no dataset, bem como a remoção de características específicas (como CRIM e NOX) em testes isolados para observar o impacto no classificador.

- Divisão de Treino e Teste: Utilizando a função `train_test_split` do Scikit-learn, os dados foram divididos em 80% para o treinamento dos algoritmos e 20% para a validação, fixando o parâmetro `random_state=42` para garantir a reprodutibilidade dos resultados.
- Escalonamento (Scaling): Para evitar que variáveis com grandezas muito distintas dominassem o modelo, testou-se a normalização e padronização dos dados aplicando os métodos `MinMaxScaler` e `StandardScaler`.
- Modelagem e Treinamento: Dois algoritmos distintos da biblioteca Scikit-learn foram instanciados e treinados para entender os padrões dos dados:
 - Regressão Linear (`LinearRegression`): Aplicada para modelar a relação linear entre os atributos precursores e prever diretamente o valor contínuo dos imóveis.
 - Random Forest (`RandomForestClassifier`): Um algoritmo de ensemble baseado em múltiplas árvores de decisão (instanciado com `n_estimators=100`), aplicado no projeto como um classificador para categorizar as faixas de preços.

3. Resultados

Os modelos foram avaliados utilizando a amostra de validação (20% dos dados separados previamente). O desempenho variou consideravelmente de acordo com a natureza de cada algoritmo, sendo os principais resultados descritos a seguir:

Desempenho do Modelo de Regressão Linear: Sendo um modelo focado em predição contínua, a Regressão Linear apresentou um comportamento robusto e consistente na captura da tendência de preços. Os testes apontaram que as métricas se mantiveram constantes e independentes da técnica de escalonamento aplicada, obtendo-se o seguinte resultado:

- MAE (Erro Médio Absoluto): 3.189 (indicando que o modelo erra o valor do imóvel, em média, por cerca de 3,18 mil dólares).
- MSE (Erro Quadrático Médio): 24.291.
- RMSE (Raiz do Erro Quadrático Médio): 4.928.
- R^2 (Coeficiente de Determinação): 0.668 (o que significa que o modelo conseguiu explicar aproximadamente 66,8% da variação total dos valores imobiliários locais).

Desempenho do Modelo Random Forest (Classificador): O algoritmo classificador foi submetido a diferentes configurações de atributos e transformações. Os experimentos

revelaram que a remoção de colunas preditoras (como CRIM e NOX) prejudicou o modelo, reduzindo a acurácia para a faixa de 12,7% a 13,7%. O melhor desempenho deste modelo ocorreu mantendo todas as variáveis originais, com os seguintes resultados:

- Acurácia (Accuracy Score): 16,6% (0.166) alcançada com os dados não escalonados, e 15,6% (0.156) com a aplicação das técnicas de normalização.

Acurácia: 0.16666666666666666

Matriz de confusão:

```
[[0 0 0 ... 0 0 0]
 [0 1 1 ... 0 0 0]
 [0 0 0 ... 0 0 0]
 ...
 [0 0 0 ... 0 0 1]
 [0 0 0 ... 0 0 0]
 [0 0 0 ... 0 0 1]]
```

Relatório de classificação:

	precision	recall	f1-score	support
5.0	0.00	0.00	0.00	1
7.0	0.33	0.50	0.40	2
8.0	0.00	0.00	0.00	0
10.0	0.00	0.00	0.00	4
11.0	0.00	0.00	0.00	2
12.0	0.00	0.00	0.00	0
13.0	0.11	0.25	0.15	4
14.0	0.00	0.00	0.00	5
15.0	0.00	0.00	0.00	4
16.0	0.00	0.00	0.00	2
17.0	0.00	0.00	0.00	6
18.0	0.14	0.17	0.15	6
19.0	0.00	0.00	0.00	6
...				
accuracy			0.17	102
macro avg	0.13	0.13	0.11	102
weighted avg	0.23	0.17	0.16	102

Acurácia: 0.1568627450980392

Matriz de confusão:

```
[[0 0 0 ... 0 0 0]
 [0 1 1 ... 0 0 0]
 [0 0 0 ... 0 0 0]
 ...
 [0 0 0 ... 0 0 1]
 [0 0 0 ... 0 0 0]
 [0 0 0 ... 0 0 1]]
```

Relatório de classificação:

	precision	recall	f1-score	support
5.0	0.00	0.00	0.00	1
7.0	0.33	0.50	0.40	2
8.0	0.00	0.00	0.00	0
10.0	0.00	0.00	0.00	4
11.0	0.00	0.00	0.00	2
12.0	0.00	0.00	0.00	0
13.0	0.11	0.25	0.15	4
14.0	0.00	0.00	0.00	5
15.0	0.00	0.00	0.00	4
16.0	0.00	0.00	0.00	2
17.0	0.00	0.00	0.00	6
18.0	0.14	0.17	0.15	6
19.0	0.00	0.00	0.00	6
...				
accuracy			0.16	102
macro avg	0.12	0.12	0.10	102
weighted avg	0.22	0.16	0.15	102

- Relatório de Classificação (Classification Report): Exibiu de forma detalhada o desempenho incluindo Precisão, Recall e F1-Score, permitindo avaliar como o algoritmo se comportou em cenários específicos do dataset
- F1-Score (Média Ponderada): 0.16.

4. Discussão

A análise dos resultados permitiu observar como diferentes algoritmos podem apresentar desempenhos bastante distintos quando aplicados ao mesmo conjunto de dados. No caso deste trabalho, a Regressão Linear obteve resultados mais satisfatórios, conseguindo explicar cerca de 66,8% da variação dos preços dos imóveis. Isso mostra que existe uma relação significativa entre as características presentes no dataset e o valor das residências, permitindo que o modelo realize previsões com um nível razoável de precisão.

As métricas de erro também indicam que o modelo apresentou um desempenho consistente. Em média, a diferença entre o valor previsto e o valor real dos imóveis foi relativamente pequena quando comparada à faixa de preços existente no conjunto de dados. Outro ponto interessante foi que a aplicação de técnicas de normalização e

padronização praticamente não alterou os resultados da Regressão Linear, demonstrando que o modelo já conseguia lidar adequadamente com os dados disponíveis.

Por outro lado, o Random Forest apresentou um desempenho inferior quando utilizado como classificador. A acurácia máxima obtida foi de apenas 16,6%, indicando dificuldade em identificar corretamente as categorias de preços definidas para o problema. Esse resultado pode ser explicado pelo fato de que o conjunto Boston Housing foi originalmente desenvolvido para tarefas de regressão, em que o objetivo é prever valores contínuos. Ao transformar esses valores em classes, parte das informações presentes nos dados acaba sendo perdida, tornando a tarefa mais complexa para o algoritmo.

Também foi possível perceber que a remoção de algumas variáveis reduziu ainda mais o desempenho do modelo. Isso sugere que atributos como CRIM e NOX possuem influência relevante na determinação do preço dos imóveis e contribuem para a capacidade preditiva do algoritmo. Dessa forma, os experimentos mostraram que a seleção de atributos deve ser realizada com cuidado, já que a exclusão de informações importantes pode prejudicar significativamente os resultados.

Além disso, verificou-se que o escalonamento dos dados não trouxe melhorias perceptíveis para o Random Forest. Esse comportamento já era esperado, pois algoritmos baseados em árvores de decisão normalmente não dependem da escala dos atributos para realizar suas divisões e classificações.

De maneira geral, os resultados reforçam a importância de escolher o modelo adequado para cada tipo de problema. Enquanto a Regressão Linear demonstrou ser uma abordagem eficiente para prever valores imobiliários, o Random Forest, utilizado como classificador, encontrou dificuldades para representar adequadamente os padrões presentes nos dados. Assim, o trabalho evidencia como a compreensão do problema e das características do conjunto de dados é fundamental para a obtenção de modelos mais precisos e confiáveis.

5. Conclusão

A análise exploratória de dados e as matrizes de correlação evidenciaram que fatores estruturais e socioeconômicos — com destaque para o número de quartos e o status social do bairro — exercem impacto direto sobre o preço médio dos imóveis (MEDV).

O modelo de Regressão Linear apresentou-se adequado para o cenário analisado, atingindo um Coeficiente de Determinação (R^2) de 0,668 (explicando 66,8% da variância dos preços) e um Erro Médio Absoluto (MAE) de aproximadamente 3,19 mil dólares. Ademais, constatou-se que a aplicação de técnicas de escalonamento, tais como MinMaxScaler ou StandardScaler, não resultou em alterações significativas no desempenho preditivo do modelo.

Em contrapartida, a abordagem utilizando o algoritmo Random Forest como classificador para predição de faixas de preço demonstrou desempenho insatisfatório, registrando acurácia máxima de apenas 16,6%. Esse resultado decorre do processo de discretização do preço (originalmente uma variável contínua) em categorias discretas, o que acarretou perda de variabilidade e de detalhes informacionais dos dados. Experimentos adicionais revelaram que a supressão de variáveis preditoras relevantes, como a taxa de criminalidade (CRIM) e a concentração de óxido nítrico (NOX), degradou substancialmente a capacidade de generalização do algoritmo, reduzindo a acurácia para o intervalo entre 12,7% e 13,7%.

Em suma, o presente estudo demonstra que a eficácia de um modelo preditivo fundamenta-se na compreensão aprofundada do comportamento estatístico dos dados e na seleção de algoritmos congruentes com a natureza da variável alvo.

6. Referências

- HARRISON, David; RUBINFELD, Daniel
L. Hedonic housing prices and the demand for clean air. *Journal of Environmental Economics and Management*, v. 5, n. 1, p. 81-102, 1978.
- PEDREGOSA, Fabian et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.
- MCKINNEY, Wes. Data structures for statistical computing in python. In: *Proceedings of the 9th Python in Science Conference*. 2010. p. 51-56. (Utilizado para a biblioteca Pandas e manipulação da estrutura dos dados).
- WASKOM, Michael
L. Seaborn: statistical data visualization. *Journal of Open Source Software*, v. 5, n. 53, p. 2121, 2020.
- HUNTER, John D. Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, v. 9, n. 3, p. 90-95, 2007.